Etapa 2 de la iniciativa de investigación del uso de modelación estocástica para la reforestación

Angel Eduardo-Luna[a], Irasema Alvarez[a], Carolina Sánchez Meneses[a], Andrea Estefanía de la Peña[a]

[a] *Instituto Tecnológico y de Estudios Superiores de Monterrey, MA2004B— Grupo 202, equipo 5*

Resumen

Este documento corresponde a la segunda etapa del proyecto. Se formula el modelo que determina cuántas plantas de cada especie adquirir por polígono cuando el número de plantas existentes y la supervivencia de las nuevas son inciertos, sujeto a la meta de 658 plantas por hectárea, al margen de ajuste por especie y al presupuesto. Se formula además la asignación espacial de las especies como un problema de coloración con penalización sobre un mosaico periódico de la retícula de plantación, resuelto mediante un algoritmo memético.

Palabras clave: reforestación, programación estocástica, restricciones de probabilidad, simulación Monte Carlo, aproximación por promedio muestral, algoritmo memético, búsqueda tabú

1. Modelo de compra bajo incertidumbre

El problema se descompone en dos niveles: la determinación de la cantidad de plantas por especie a adquirir en cada polígono y su asignación espacial dentro de la retícula de plantación. Esta sección formula el primero; sus resultados constituyen los datos de entrada del segundo. La compra se decide sin conocer el número de plantas ya establecidas ni la supervivencia de las nuevas, por lo que se plantea como un programa estocástico con restricciones de probabilidad.

1.1. Datos y parámetros

Sea $\mathcal{S}$ el conjunto de las diez especies e i un polígono de superficie A_i (ha). Para cada $s \in \mathcal{S}$, n_s^0 denota la densidad del plan de reforestación ($\sum_s n_s^0 = 658$ plantas/ha), c_s el costo unitario de la planta excluida la logística, q_s y $q_{2|1,s}$ las supervivencias del primer año y del segundo año condicionada a la del primero, observadas en el monitoreo de 2022 y 2023, respectivamente, y λ_s la densidad media de plantas existentes, estimada como $\hat{\lambda}_s = \sum_i E_{is} / \sum_i A_i$ a partir de los conteos E_{is} de los 30 polígonos ($\sum_i A_i = 183.01$ ha). Los valores se reportan en la tabla 1. Se consideran además cuatro parámetros de política: el presupuesto por hectárea B, fijado por el socio formador en \$12,500; el sobrecosto logístico $\theta \in [0.05, 0.10]$, expresado como fracción del costo de la planta; la desviación máxima por especie respecto al plan, $\delta = 0.10$; y el riesgo admisible de incumplimiento, $\alpha = 0.05$.

1.2. Variables aleatorias

El número de plantas existentes de la especie s en el polígono i se modela como $E_{is} \sim \text{Poisson}(\lambda_s A_i)$, lo que corresponde a una dispersión espacial aleatoria con intensidad λ_s. El supuesto de equidispersión es consistente con los datos: $\hat{\phi}_s \in [0.58, 1.45]$ para todas las especies, sin evidencia de la sobredispersión que justificaría una binomial negativa (Cameron & Trivedi, 2013). En consecuencia, $\mathbb{E}[E_{is}] = \lambda_s A_i$, y la densidad esperada de plantas existentes es de 128.8 plantas/ha (19.6 % de la meta). Bajo independencia entre individuos, el número de sobrevivientes de x plantas nuevas es $S_{is}(x) \sim \text{Bin}(x, q_s)$.

1.3. Formulación

Sean $n_{is} \in \mathbb{Z}_{\geq 0}$ la meta de plantas de la especie s en el polígono i y $x_{is} \in \mathbb{Z}_{\geq 0}$ la cantidad a adquirir. La tabla 2 resume la notación del modelo. Para cada polígono se resuelve

$$\min_{n,\,x} \quad (1+\theta)\sum_s c_s x_{is} + \sum_s c_s^R\,\mathbb{E}[D_{is}] \tag{1}$$

$$\text{s.a.} \quad \sum_s n_{is} = 658\,A_i, \tag{2}$$

$$\left|n_{is} - n_s^0 A_i\right| \leq \delta\, n_s^0 A_i, \tag{3}$$

$$(1+\theta)\sum_s c_s x_{is} \leq B\,A_i, \tag{4}$$

$$\mathbb{P}(E_{is} + S_{is}(x_{is}) \geq n_{is}) \geq 1-\alpha, \tag{5}$$

donde $D_{is} = (n_{is} - E_{is} - S_{is}(x_{is}))^+$ es el déficit al término del primer año y c_s^R el costo unitario de reposición, incluida su logística. El objetivo (1) agrega el costo de adquisición y el costo esperado de reposición; este último representa la obligación contractual de reponer la planta muerta, que recae en el contratista cuando el contrato no la asigna. La restricción (2) fija la densidad total; (3) acota la composición por especie; (4) limita el gasto, y (5) exige que la meta de cada especie se alcance con probabilidad de al menos $1-\alpha$ (Charnes & Cooper, 1959).

Tabla 1: Parámetros por especie. $\hat{\phi}_s$: estadístico de dispersión de Pearson de los conteos E_{is} respecto a $\hat{\lambda}_s A_i$; $q_{2|1,s}$: supervivencia en el segundo año condicionada a la supervivencia en el primero.

Especie	n_s^0 (plantas/ha)	c_s ($)	$\hat{\lambda}_s$ (plantas/ha)	$\hat{\phi}_s$	q_s	$q_{2\|1,s}$
Agave lechuguilla	42	26.0	8.1	1.45	0.943	0.927
Agave salmiana	196	26.0	38.0	0.85	0.959	0.908
Agave scabra	42	26.0	8.0	0.93	0.825	0.745
Agave striata	42	26.0	7.7	1.03	0.952	0.914
Opuntia cantabrigiensis	49	18.0	10.0	1.26	0.927	0.829
Opuntia engelmannii	38	21.0	8.0	0.87	0.899	0.819
Opuntia robusta	73	18.0	15.0	0.58	0.958	0.920
Opuntia streptacantha	64	18.0	12.5	1.13	0.886	0.853
Prosopis laevigata	86	26.5	16.5	1.35	0.821	0.818
Yucca filifera	26	26.0	5.0	0.90	0.884	0.726
Total	658		128.8			

Tabla 2: Notación del modelo de compra.

Símbolo	Tipo	Descripción	Unidad o valor
$\mathcal{S}$, s	Conjunto e índice	Especies a plantar	10 especies
i	Índice	Polígono de reforestación	30 polígonos
A_i	Dato	Superficie del polígono i	ha
n_s^0	Dato	Plantas de la especie s por hectárea según el plan de reforestación	plantas/ha; $\sum_s n_s^0 = 658$
c_s	Dato	Costo unitario de la planta, sin logística	$/planta
λ_s	Parámetro estimado	Densidad media de plantas existentes de la especie s	plantas/ha
q_s	Parámetro estimado	Probabilidad de que una planta nueva sobreviva el primer año	$[0, 1]$
B	Parámetro de política	Presupuesto por hectárea	$12,500
θ	Parámetro de política	Sobrecosto logístico como fracción del costo de la planta	[0.05, 0.10]
δ	Parámetro de política	Desviación relativa máxima de la meta de cada especie respecto al plan	0.10
α	Parámetro de política	Probabilidad admisible de no alcanzar la meta de una especie	0.05
c_s^R	Parámetro de política	Costo unitario de reposición, incluida la logística	$/planta
E_{is}	Variable aleatoria	Plantas existentes de la especie s en el polígono i; $E_{is} \sim$ Poisson$(\lambda_s A_i)$	plantas
$S_{is}(x)$	Variable aleatoria	Sobrevivientes al primer año de x plantas nuevas; $S_{is}(x) \sim$ Bin(x, q_s)	plantas
D_{is}	Variable aleatoria	Déficit al término del primer año, $(n_{is} - E_{is} - S_{is})^+$	plantas
n_{is}	Variable de decisión	Meta de plantas de la especie s en el polígono i	plantas; entera
x_{is}	Variable de decisión	Plantas de la especie s a adquirir y plantar en el polígono i	plantas; entera

Con la composición del plan, el costo del déficit esperado, $\sum_s c_s(n_s^0 - \lambda_s)$, asciende a $12,456/ha, y a $13,683/ha al corregirlo por la mortalidad del primer año, $\sum_s c_s(n_s^0 - \lambda_s)/q_s$. Con $B = \$12{,}500$, la restricción (4) es por tanto prácticamente activa, y la factibilidad depende de la banda (3), que permite desplazar la composición hacia especies con menor costo por planta sobreviviente c_s/q_s ($18.8 para *O. robusta* frente a $32.3 para *P. laevigata*). En caso de infactibilidad, el modelo proporciona el presupuesto o el riesgo α mínimos compatibles con la meta.

1.4. Método de solución

Las especies se acoplan únicamente mediante (2) y (4), lo que permite resolver el problema en dos etapas.

En la primera, para cada especie s y cada meta candidata n en la banda (3), se generan K escenarios $\left(E^{(k)}, S^{(k)}(x)\right)$ por simulación Monte Carlo (Ross, 2013) y se estima la probabilidad de cumplimiento $\hat{p}(x) = K^{-1} \sum_k \mathbf{1}\{E^{(k)} + S^{(k)}(x) \geq n\}$. Dado que $\hat{p}$ es no decreciente en x, la compra mínima $x_s^*(n)$ que satisface $\hat{p}(x) \geq 1 - \alpha$ se obtiene por bisección. Con los mismos escenarios se estima el déficit esperado $\hat{D}_s(n)$ y se calcula el costo $C_s(n) = (1 + \theta)c_s x_s^*(n) + c_s^R \hat{D}_s(n)$. Se emplean números aleatorios comunes entre candidatos para reducir la varianza de las comparaciones.

En la segunda, la elección de una meta n_s por especie que minimice $\sum_s C_s(n_s)$ sujeta a (2) y (4) es un problema de mochila de elección múltiple, que se resuelve de forma exacta mediante programación dinámica o programación entera.

El procedimiento constituye una aproximación por promedio muestral (SAA) del programa (1)–(5), cuya solución converge a la del problema original al crecer K (Kleywegt et al., 2002; Luedtke & Ahmed, 2008). Para un semian-

cho $\varepsilon = 0.005$ del intervalo de confianza de 95 % de $\hat{p}$ en $p = 0.95$ se requiere $K \geq z^2_{0.025} p(1-p)/\varepsilon^2 \approx 7{,}300$; se adopta $K = 10{,}000$.

1.5. Supuestos y extensiones

El modelo descansa en cuatro supuestos. (i) La supervivencia es independiente entre individuos; los eventos que afectan a toda la plantación, como la sequía, incrementan la varianza de S_{is} y pueden incorporarse sorteando por escenario una tasa común $q_s^{(k)}$, aunque un solo año de monitoreo no permite estimar su dispersión. (ii) Las plantas existentes no mueren durante el horizonte; si se conoce su supervivencia anual r_s, basta sustituir λ_s por $\lambda_s r_s$ (adelgazamiento de Poisson). (iii) El horizonte es de un año, aunque la mortalidad del segundo año es incluso mayor que la del primero (15.4 % frente a 9.5 % en promedio, con $q_{2|1,s}$ entre 0.726 y 0.927); para obligaciones de reposición multianuales, el término de reposición se extiende mediante una cadena de Markov por posición con estados {vacía, plántula, establecida}, estimada con q_s y $q_{2|1,s}$. (iv) El costo logístico es proporcional al costo de la planta; los costos fijos por viaje o por vivero se incorporan con variables binarias de activación sin alterar la estructura del modelo.

2. Modelo de distribución espacial

El segundo nivel asigna las plantas adquiridas en la sección 1 a posiciones del terreno para minimizar la competencia entre plantas vecinas. Se adopta la sobreplantación: se plantan todas las plantas adquiridas y la mortalidad del primer año reduce la densidad hacia la meta de 658 plantas/ha. El terreno se modela como un grafo cuyos vértices son las posiciones de plantación y cuyas aristas unen posiciones vecinas; el problema consiste en asignar una especie a cada vértice respetando la cantidad por especie (Eisenblätter et al., 2002; Elizalde-Ramirez et al., 2025).

Retícula. En pendientes superiores al 20 % se emplea el tresbolillo, una retícula triangular con seis vecinas equidistantes por posición que reduce la erosión; en pendientes menores, el arreglo en cuadros, con cuatro vecinas ortogonales y cuatro diagonales de menor peso por su mayor distancia. La configuración determina la competencia mínima alcanzable: *A. salmiana*, cercana al 28 % de la plantación, puede aislarse de sus congéneres al tresbolillo, pero no en cuadros.

Matriz de competencia. Una matriz simétrica cuantifica, para cada par de especies, la penalización por ocupar posiciones vecinas; su diagonal representa la competencia intraespecífica. Se construirá con funciones de correlación de pares bivariadas sobre la distribución de las plantas establecidas, que indican asociación o segregación entre especies (Wiegand & Moloney, 2014), complementadas con literatura ecológica del matorral desértico. La tabla 3 presenta la estimación preliminar: el valor 1 corresponde a ausencia de penalización, los valores mayores que 1 a penalización y los menores que 1 a una interacción favorable. Solo cinco pares superan la unidad, todos intraespecíficos (*P. laevigata*, *O. streptacantha*, *Y. filifera*, *A. salmiana* y *O. engelmannii*), y *P. laevigata* presenta los valores más bajos con el resto de las especies. Como cada arista aporta exactamente un término al objetivo, la asignación óptima es invariante ante cualquier transformación afín positiva de la matriz, de modo que su reescalamiento no altera la solución.

Tabla 3: Matriz de competencia W_{ab} preliminar. ALE: *A. lechuguilla*; ASA: *A. salmiana*; ASC: *A. scabra*; AST: *A. striata*; OCA: *O. cantabrigiensis*; OEN: *O. engelmannii*; ORO: *O. robusta*; OST: *O. streptacantha*; PLA: *P. laevigata*; YFI: *Y. filifera*. En negritas, los valores mayores que 1.

	ALE	ASA	ASC	AST	OCA	OEN	ORO	OST	PLA	YFI
ALE	0.20	0.50	0.30	0.21	0.30	0.42	0.24	0.54	0.20	0.49
ASA	0.50	**1.29**	0.67	0.57	0.67	0.79	0.61	0.90	0.20	0.82
ASC	0.30	0.67	0.72	0.38	0.48	0.60	0.42	0.71	0.20	0.65
AST	0.21	0.57	0.38	0.43	0.38	0.50	0.32	0.62	0.20	0.56
OCA	0.30	0.67	0.48	0.38	0.72	0.60	0.42	0.72	0.17	0.63
OEN	0.42	0.79	0.60	0.50	0.60	**1.07**	0.54	0.84	0.17	0.74
ORO	0.24	0.61	0.42	0.32	0.42	0.54	0.54	0.66	0.17	0.58
OST	0.54	0.90	0.71	0.62	0.72	0.84	0.66	**1.43**	0.17	0.84
PLA	0.20	0.20	0.20	0.20	0.17	0.17	0.17	0.17	**1.50**	0.45
YFI	0.49	0.82	0.65	0.56	0.63	0.74	0.58	0.84	0.45	**1.43**

Planteamiento. La optimización se realiza sobre un mosaico de pocas decenas de posiciones con bordes periódicos, que la cuadrilla replica sobre el polígono como una tabla de claves de especie. El objetivo es la competencia total, suma sobre los pares de posiciones vecinas de la penalización de sus especies ponderada por la distancia. Se reporta además un coeficiente de competencia, cociente entre la competencia de la asignación y su valor esperado bajo una asignación aleatoria de igual composición, de modo que valores menores que uno indican una reducción respecto al azar. El problema es una coloración de vértices con penalización, NP-difícil (Eisenblätter et al., 2002), y se resuelve con dos métodos que comparten el objetivo: un algoritmo memético y un modelo de programación entera cuyo óptimo, o cota inferior, mide la brecha del primero. La secuencia vigente de 21 posiciones sirve de línea base.

2.1. Algoritmo memético

El algoritmo combina un algoritmo genético, que explora mediante recombinación, con búsqueda tabú, que intensifica alrededor de cada descendiente; esta hibridación supera a cada componente por separado en coloración de grafos (Galinier & Hao, 1999).

Representación e inicialización. Un individuo asigna una especie a cada posición del mosaico respetando la composición de la sección 1; su aptitud es la competencia total. La población inicial ($P = 20$) se forma con permutaciones aleatorias de la composición y con la línea base vigente, que garantiza no empeorar el esquema actual; cada individuo se mejora con búsqueda tabú.

Selección y cruce. Los padres se eligen por torneo binario. El cruce adapta el operador GPX (Galinier & Hao, 1999): alternando entre padres, se elige la especie con más posiciones libres en el padre en turno y el hijo las hereda hasta completar su cantidad; las posiciones restantes se asignan de forma voraz a la especie que menos incrementa la competencia. A diferencia de la coloración, las especies no son intercambiables, por lo que el operador procede por especie y conserva la composición por construcción. Como dos mosaicos desplazados son equivalentes, el segundo padre se traslada antes del cruce a la posición de máxima coincidencia con el primero.

Búsqueda tabú. Cada hijo se mejora con búsqueda tabú (Glover, 1989; Hertz & de Werra, 1987) sobre intercambios de especie entre dos posiciones, que conservan la composición y cuyo efecto se evalúa solo en las vecinas de ambas. Se aplica el mejor intercambio no prohibido y se prohíbe revertirlo durante 5 a 15 iteraciones, salvo que produzca una nueva mejor solución; la búsqueda termina tras 500 iteraciones sin mejora.

Reemplazo y paro. El hijo sustituye al peor individuo si lo mejora y no es una copia de otro, con la distancia medida como el número de posiciones distintas minimizado sobre las traslaciones del mosaico, lo que preserva la diversidad. El algoritmo termina tras 1,000 generaciones o 100 sin mejora. Se ejecutan 30 corridas independientes y se reportan la mejor competencia, su media y su desviación estándar; los parámetros se calibrarán experimentalmente.

2.2. Modelo de programación entera

Sea $G = (V, \mathcal{E})$ el grafo del mosaico con bordes periódicos, w_{uv} el peso por distancia de la arista (u, v), W_{ab} la penalización entre las especies a y b, y m_s el número de posiciones de la especie s. Con $y_{vs} \in \{0, 1\}$, igual a 1 si la posición v recibe la especie s, y $z_{uvab} \geq 0$, que representa el producto $y_{ua} y_{vb}$, se resuelve

$$\text{mín} \quad \sum_{(u,v)\in\mathcal{E}} w_{uv} \sum_{a,b\in\mathcal{S}} W_{ab}\, z_{uvab} \tag{6}$$

$$\text{s.a.} \quad \textstyle\sum_s y_{vs} = 1, \qquad v \in V, \tag{7}$$

$$\textstyle\sum_v y_{vs} = m_s, \qquad s \in \mathcal{S}, \tag{8}$$

$$\textstyle\sum_b z_{uvab} = y_{ua}, \qquad (u,v) \in \mathcal{E},\ a \in \mathcal{S}, \tag{9}$$

$$\textstyle\sum_a z_{uvab} = y_{vb}, \qquad (u,v) \in \mathcal{E},\ b \in \mathcal{S}. \tag{10}$$

Las restricciones (7) y (8) imponen una especie por posición y la composición; (9)–(10) linealizan el objetivo cuadrático, pues con y binaria fuerzan $z_{uvab} = y_{ua} y_{vb}$ sin depender del signo de W. Como el mosaico es invariante bajo traslaciones, se fija la especie más abundante en una posición, lo que elimina soluciones equivalentes sin pérdida de optimalidad. Con un mosaico de 52 posiciones al tresbolillo, el modelo tiene 520 variables binarias y cerca de 1.6×10^4 continuas, y se resuelve con un solver de programación entera mixta con límite de tiempo; la cota inferior reportada mide la brecha del algoritmo memético.

Referencias

Cameron, A. C., & Trivedi, P. K. (2013). *Regression Analysis of Count Data* (2.ª ed.). Cambridge University Press.

Charnes, A., & Cooper, W. W. (1959). Chance-Constrained Programming. *Management Science*, *6*(1), 73-79. https://doi.org/10.1287/mnsc.6.1.73

Eisenblätter, A., Grötschel, M., & Koster, A. M. C. A. (2002). Frequency planning and ramifications of coloring. *Discussiones Mathematicae Graph Theory*, *22*, 51-88. https://www.dmgt.uz.zgora.pl/publish/pdf.php?doi=1158

Elizalde-Ramirez, F., Maya-Padron, C., & Jimenez-Martínez, M.-G. (2025). Minimization of competition between flora species in a reforestation area. En L. Martínez-Villaseñor, R. A. Vázquez & G. Ochoa-Ruiz (Eds.), *Advances in soft computing. MICAI 2025 posters track* (pp. 16-27). Springer Nature Switzerland. https://doi.org/10.1007/978-3-032-08704-1_2

Galinier, P., & Hao, J.-K. (1999). Hybrid Evolutionary Algorithms for Graph Coloring. *Journal of Combinatorial Optimization*, *3*(4), 379-397. https://doi.org/10.1023/A:1009823419804

Glover, F. (1989). Tabu Search—Part I. *ORSA Journal on Computing*, *1*(3), 190-206. https://doi.org/10.1287/ijoc.1.3.190

Hertz, A., & de Werra, D. (1987). Using Tabu Search Techniques for Graph Coloring. *Computing*, *39*(4), 345-351. https://doi.org/10.1007/BF02239976

Kleywegt, A. J., Shapiro, A., & Homem-de-Mello, T. (2002). The Sample Average Approximation Method for Stochastic Discrete Optimization. *SIAM Journal on Optimization*, *12*(2), 479-502. https://doi.org/10.1137/S1052623499363220

Luedtke, J., & Ahmed, S. (2008). A Sample Approximation Approach for Optimization with Probabilistic Constraints. *SIAM Journal on Optimization*, *19*(2), 674-699. https://doi.org/10.1137/070702928

Ross, S. M. (2013). *Simulation* (5.ª ed.). Academic Press.

Wiegand, T., & Moloney, K. A. (2014). *Handbook of Spatial Point-Pattern Analysis in Ecology*. CRC Press.